



El lenguaje natural es considerado un rasgo distintivo de la inteligencia humana

- Se define como el lenguaje hablado y escrito que utilizamos a diario
- Es el mayor depósito de conocimiento humano que existe
- Permite la interacción hombre-máquina mediante sistemas que entienden el lenguaje

Abordaremos el NLP desde el punto de vista del aprendizaje profundo

- Veremos diferentes formas de representar el lenguaje y la solución más adoptada: los embeddings
- También resolveremos problemas usando CNN y RNN

Aprendizaje profundo 2 / 64

Introducción



¿Qué es el procesamiento de lenguaje natural?

Área de la IA que cubre la comprensión y generación de lenguaje natural

- No está limitado únicamente al texto (p.ej. también hablado, lengua de signos, ...)
- Está mucho más avanzado en texto escrito (es del que hay más datos disponibles)
- También está relacionado con otros campos como la lingüística, la psicolingüística, las ciencias cognitivas y la estadística
- Uno de sus objetivos es conseguir que los ordenadores trbajen con nuestro lenguaje en lugar de trabajar nosotros con el suyo

Por cierto, la voz artificial suena cada vez más natural

• Con inflexiones tonales y prosódicas que imitan la producción humana (p.ej. VALL-E)

No pertenece únicamente al campo de la IA

Aprendizaje profundo 4 / 64



Áreas de trabajo en NLP

Podemos dividir el NLP en dos áreas de trabajo bien diferenciadas:

- 1. Natural language generation (NLG): Generación de lenguaje a partir de representaciones internas
 - o Puede considerarse como un componente de traducción entre los datos y el lenguaje natural
 - o Se subdivide en múltiples tareas: planificación del discurso, selección léxica, ...
- 2. Natural language understanding (NLU): Comprensión lectora de las máquinas
 - o Transformar el lenguaje natural en una representación adecuada para la máquina
 - Normalmente, requiere diferentes niveles de análisis: morfológico, sintáctico, semántico, discurso, ...

El NLU es mucho más complejo que NLG. Dicho esto, *ambos problemas son muy difíciles*

¹ Artículo: Logical syntax and semantics: Their linguistic relevance



Los dos enfoques principales en NLP

Basados en gramáticas o modelos lógicos: Enfoque top-down

- Diseñados para intentar reflejar la estructura lógica del lenguaje
- Surgen de las teorías lingüísticas de N. Chomsky a mediados de los 1950¹
- Desarrollar reglas de reconocimiento de patrones estructurales, utilizando un formalismo gramatical específico
- Los patrones de reconocimiento se definen por las reglas e información adicional

Basados en datos: Enfoque bottom-up

- Abarcan tanto modelos probabilísticos como basados en machine learning
- Se parte de ejemplos para calcular su probabilidad de aparición en un contexto
- Permiten predecir la siguiente unidad en un contexto determinado sin reglas gramaticales explícitas

Aprendizaje profundo 6 / 64



Ventajas y desventajas

Ventajas

- Un usuario podría hacer preguntas en su idioma natal en lugar de aprender una sintaxis de consulta específica
- La exactitud de las respuestas tiende a aumentar según aumenta la cantidad de información relevante en la pregunta
- Las respuestas se pueden ofrecer en el idioma del usuario

Desventajas

- El sistema puede no ser capaz de dar una respuesta correcta si la pregunta está mal formulada o es ambigua
- Los sistemas se construyen para una tarea única y específica
 - Son incapaces de adaptarse a nuevos problemas

Aprendizaje profundo 7 / 64

Ejemplos de aplicaciones



Recordatorio de tipos de problema

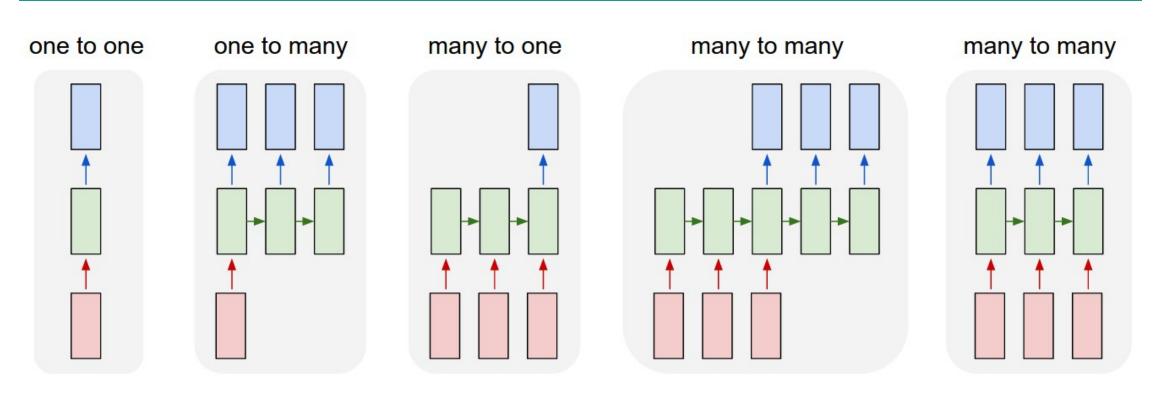


Figura 1 Recordatorio de los diferentes tipos de problema existentes con modelos de redes neuronales.

Aprendizaje profundo 9 / 64



Aplicaciones one-to-many

En NLP no existen demasiadas aplicaciones one-to-many

• Después de todo, una parte del NLP es el NLU, que trabaja con secuencias de entrada

Las que existen suelen trabajar a partir de una semilla inicial para generar texto

- Etiquetado de vídeos
- Creación de pies de foto para imágenes

Aprendizaje profundo 10 / 64



Aplicaciones many-to-one

Tenemos, por ejemplo, los motores de búsqueda como Google, Yahoo o Bing

- El motor de búsqueda de Google incluso entiende tanto el texto como el contexto
 - La misma query para dos personas o momentos diferentes arroja resultados diferentes

Redes sociales como Facebook infieren información de los intereses de los usuarios

• También de los contenidos generados por los usuarios en forma de publicaciones (a ver si no por qué iban a haber pagado tanto por WhatsApp)

En general, soluciones para clasificar texto

• Filtrado de spam², procesamiento de historiales clínicos³, detección de paráfrasis, ...

² Artículo: Deep learning to filter SMS Spam

Aprendizaje profundo 11 / 64

³ Artículo: Natural Language Processing of Clinical Notes on Chronic Diseases: Systematic Review

Universidad Politicenica de Madrid INFORMÁTICOS

Aplicaciones many-to-many

Un ejemplo típico es el de los asistentes virtuales, como Siri (Apple) o Alexa (Amazon)

• Existen también implementaciones como Open Assistant⁴, Mycroft Al⁵ y Dragonfire⁶

Generación de información a partir de una secuencia de datos previa

• Generación de sugerencias de continuación de una frase o incluso ¡juegos completos!⁷

Recordemos que las many-to-many también funcionan como $T_x = T_y$

• Etiquetado gramatical, corrección ortográfica⁸, ...

4 Proyecto: Open Assistant

5 Proyecto: Mycroft Al

6 Proyecto: Dragonfire

⁷ El juego Al Dungeon es una aventura conversacional totalmente generada por un modelo de lenguaje basado en un modelo propio de lenguaje (originalmente fue GPT-2)

8 Artículo: Personalized spell checking using neural networks.

Representación del lenguaje

Universidad Politécnica Politécnica INFORMÁTICOS

n-gramas

Combinaciones de palabras cercanas, siendo n el número de palabras que se combinan

Consideremos la frase: "el deep learning es la leche"

- Modelo 1-gramas (unigrama): convierte la frase en una secuencia de palabras
 (el, deep, learning, es, la, leche)
- Modelo 2-gramas (bigrama): convierte la frase en combinaciones de dos palabras
 (el, deep), (deep, learning), (learning, es), (es, la), (la, leche)}
- Modelo 3-gramas (trigrama), 4-gramas (tetragrama), 5-gramas (pentagrama), ...

Desglosar un texto en n-gramas es un proceso muy susado en el NLP tradicional

- Esencial para mantener el recuento de conceptos en frases
- Constituye la columna vertebral de los procesos matemáticos tradicionales

14 / 64



Bag-of-Words (BoW)

Representación de un texto como el multiconjunto⁹ de sus palabras

La forma más común de representación es como formato tabular:

- Fila: Observación (e.g. un documento)
- Columna: Token (e.g. palabra, n-grama, ...)
- Celda: El recuento del token en esa observación

| ID | Agua | Archaeopteryx | Zumo |
|-----|------|---------------|------|
| 001 | 12 | 12 | 0 |
| 002 | 1 | 5 | |
| | | | |
| 999 | 35 | 0 | 13 |

Solo se trabaja con frecuencias ya que el resto de información se ha perdido

Aprendizaje profundo 15 / 64

⁹ En el contexto de la informática, un multiconjunto (bolsa o bag) es un conjunto que puede contener elementos repetidos (https://es.wikipedia.org/wiki/Multiconjunto)

PREPARÉMONOS PARA CONOCER LA VERDAD ABSOLUTA DEL NLP

LAS PALABRAS SON CADENAS DE TEXTO



(¿y el problema?)

¡EN APRENDIZAJE PROFUNDO SE TRABAJA CON NÚMEROS!

Codificación one-hot

Codificación one-hot



La codificación one-hot transforma una variable categórica en una numérica

- Por ejemplo, si nuestro alfabeto tiene sólo tres palabras quiero, comer y pizza, podemos codificarlas como
- $[1, 0, 0] \rightarrow quiero$
- $[0, 1, 0] \rightarrow comer$
- $[0, 0, 1] \rightarrow pizza$

Es rápido, sencillo, claro, ¿por qué no es una buena idea para codificar palabras?

- No es capaz de almacenar información de las relaciones con otras palabras
 - o e.g. gato y perro están igual de relacionados que gato y corneta
- El espacio que ocupa en memoria es sencillamente prohibitivo
 - o Imaginemos lo que puede llegar a ocupar la matriz del castellano

No lo imaginamos:

 $pprox 10^5$ palabras \implies matriz de $10^5 imes 10^5 = 10^{10}$ elementos (bits) pprox 1,15 GB



Vectores de palabras (word vectors)

Permite analogías con palabras: V(rey) - V(hombre) pprox V(reina) - V(mujer)

| | Género | Edad | Lugar |
|-----------|--------|------|-------|
| rey | +1 | +1 | 0 |
| reina | +1 | +1 | 0 |
| príncipe | +1 | +1 | 0 |
| princesa | +1 | +1 | 0 |
| manhattan | +1 | +1 | 0 |
| tomelloso | +1 | +1 | 0 |

- Vectores de características en NLP
- Más compactos que one-hot

[©]clusters de palabras

Figura 2. Visualización de clústers de palabras

Aprendizaje profundo 24 / 64

¿Qué características escoger para las palabras?

Es muy difícil determinar qué características son relevantes para clasificar las palabras

- ¿Qué características son las que vamos a utilizar?
- ¿Es relevante el rasgo triste? ¿Cómo medimos la tristeza de una patata?
- ¿Vamos a estudiar cada palabra individualmente?
- ¿Cuántas palabras existen en una lengua?
- Necesitamos formas automatizadas de crear esos vectores de palabras

Las características inferidas en aprendizaje no supervisado no tienen por qué tener sentido

- Solo tienen que tener sentido geométrico, dejemos que el algoritmo infiera las mejores
- Análogo a vectores latentes, como las capas internas de una red neuronal

Aprendizaje profundo 25 / 64

Universidad Politécnica Politécnica (Marid Marid INFORMÁTICOS

Embeddings

Un Embedding es simplemente una matriz de vectores de palabras apiladas

- A partir de 2013¹¹ se sentaron las bases de las técnicas actuales
- Algunos autores los denominan word embedding o word embedding matrix

Convenio:

- ullet V o Número de filas = Tamaño del vocabulario = Número de palabras distintas
- ullet D o Dimensión del embedding = Tamaño del vector de características

El transfer learning ha hecho que los embeddings sean un pilar fundamental del NLP

Veremos los dos métodos más conocidos: Word2Vec y GLoVe

¹¹ Existen desde el 2001 (A neural probabilistic language model), pero el verdadero boom fue a partir del 2013 (Distributed representations of words and phrases and their compositionality), momento en el que se mejoró su eficiencia de manera dramática.

Aprendizaie profundo

¿Cómo se usan los embeddings?



Generalmente los usaremos a través de transfer learning, lo cual es bueno porque:

- Hay gente/compañías con más recursos computacionales que nosotros
- Encontrar los mejores hiperparámetros es una tarea ardua (ensayo y error)
- Evitamos otros preprocesos sobre los datos (p.ej. mitigación del bias)

Truco computacional: Obtener el vector de palabra indexando, no multiplicando

• En Keras significa no usar una capa Dense(), sino las capas Embedding()

¿Y si el dataset tiene palabras que no existen en el embedding preentrenado?

- Abreviaturas, modismos, palabras mal escritas, ...
- Suele pasar con palabras poco comunes
- Los pesos pueden ser inicializados aleatoriamente o a 0

Aprendizaje profundo 27 / 64



¿Deberíamos entrenar los embeddings?

model.fit(X, Y) actualiza automáticamente todos los parámetros del modelo

- ¿Dejamos que se entrene el embedding? La mayoría de las bibliotecas no es tan fina
 Esto quiere decir que, o lo entrenamos entero, o no lo entrenamos
- No olvidemos de que las palabras poco comunes son, por definición, poco comunes

Por lo general, no tenemos que molestarnos en hacer un fine-tunning del embedding

- Pero a veces es bueno experimentar con nuestros propios datos
- En Keras, si lo necesitamos, basta simplemente con cambiar el atributo trainable:
 - o embedding_layer.trainable = True → fine-tunning (valor por defecto)
 - ∘ embedding_layer.trainable = False → Pesos constantes

Aprendizaje profundo 28 / 64

Word2vec



Introducción

Word2vec es una de las técnicas existentes para representar vectorialmente el texto

- Su eficacia reside en su capacidad para agrupar vectores de palabras similares
- Estima el significado de una palabra basándose en sus apariciones en el texto

Las operaciones algebraicas sobre los vectores permite jugar con sus significados

$$\bullet \ \ V(peral) - V(pera) + V(nuez) = V(nogal)$$

Existen dos arquitecturas dependiendo de su cometido

- Continous bag-of-words (CBoW): Predice una palabra basándose en las circundantes
- Skip-grams: Predice las palabras circundantes en función de la central



¿Por qué es interesante?

Sobre corpus grandes permite a las palabras relacionarse en dimensiones aprendidas

Figura 3: Relaciones entre palabras aprendidas por Word2Vec

- Surgieron muchos estudios para intentar aclarar estas relaciones lineales¹²
- Hubo estudios que demostraron que las relaciones no están exentas de sesgo¹³

¹² Algunos de estos artículos: Evaluating the stability of embedding-based word similarities, A latent variable model approach to pmi-based word embeddings, The strange geometry of skip-gram with negative sampling y Factors influencing the surprising instability of word embeddings.

¹³ Artículo Man is to computer programmer as woman is to homemaker? debiasing word embeddings.



Arquitectura CBoW (I)

Idea: Tomar los n vectores anteriores y posteriores del objetivo y sumarlos

Figura 4: Esquema de arquitectura CBoW. La suma de los vectores es duficientemente significativa para deducir la palabra.

Nota → Al igual las bag-of-words, las CBoW también eliminan el orden

Aprendizaje profundo 32 / 64



Arquitectura CBoW (II)

Ejemplo de frase: "Hoy me *voy* de parranda"; ventana: 5 palabras (\pm 2 palabras)

Figura 5:Entrenaremos el modelo indicando que debe de inferir voy a partir de hoy, me, de y parranda.

Aprendizaje profundo 33 / 64



Arquitectura CBoW (III)

Cada palabra (entrada y salida) se codifican mediante one-hot

Figura 6: Codificación de cada palabra en one-hot. Se muestran únicamente dos palabras por motivos de espacio.

Aprendizaje profundo 34 / 64



Arquitectura CBoW (IV)

Nuestro objetivo es aprender dos matrices: $W_{V imes N}$ y $W_{N imes V}'$

Figura 7: Matrices de transformacion de palabra a word vector (\$W_{V \times N}\$) y viceversa (\$W'_{N \times V}\$).

 $oldsymbol{V}$ Será el tamaño del vocabulario y $oldsymbol{N}$ la dimensión del vector de palabra

Aprendizaje profundo 35 / 64



Arquitectura CBoW (V)

El producto entre $W^t_{V imes N}$ y el <mark>one hot</mark> de una palabra nos da su vector

Figura 8: Obtención del vector de características de una palabra a partir de su codificación one hot.

Aprendizaje profundo 36 / 64



Arquitectura CBoW (VI)

El producto entre el vector de una palabra y $W'_{N imes V}$ nos da un vector de dimensión V

• Este lo aproximamos al one hot más cercano, que será el de la palabra buscada

Figura 9: Obtención de la palabra a partir de un determinado vector de características.

Aprendizaje profundo 37 / 64



Arquitectura CBoW (i VII)

Tras el entrenamiento podemos considerar la matriz $W_{V imes N}$ como el embedding

Figura 10: Nuestro embedding resultante.

Hay que destacar que:

- ullet La matriz $W'_{N imes V}$ puede servir también como capa de embedding
- De hecho, es bastante común usar ambas matrices como dicha capa

Aprendizaje profundo 38 / 64



Arquitectura skip-grams

Es la arquitectura inversa a la CBoW

• Se intentan predecir la ventana de palabras circundantes a partir de la palabra actual

Figura 11: Esquema de arquitectura skip-gram. Se deducen los vectores a partir de una determinada palabra.

Es un problema mucho menos concreto, pero empíricamente parece que escala mejor

Aprendizaje profundo 39 / 64

Universidad ETSI SISTEMAS Politécnica INFORMÁTICOS

Más allá de Word2vec

En un inicio, las relaciones obtenidas mediante word2vec parecían totalmente intuitivas

• Luego se demostró que se podían obtener mediante factorización matricial¹⁴

A pesar de los avances, word2vec sigue siendo muy utilizado en la actualidad

- Hay estudios que van desde el nivel "subpalabra" al de oración formales de la companion de l
- Trasciende el NLP, aplicandose al dominios como los grafos¹⁷ o la biología¹⁸
- Proyección de embeddings de diferentes idiomas sobre el mismo espacio vectorial¹⁹

14 Artículo Glove: Global vectors for word representation.

15 Artículo: Bag of Tricks for Efficient Text Classification (FastText).

¹⁶ Artículos: Skip-thought vectors y Distributed representations of sentences and documents.

17 Artículo: node2vec: Scalable Feature Learning for Networks.

18 Concretamente al estudio de las secuencias biológicas: Continuous distributed representation of biological sequences for deep proteomics and genomics.

19 El objetivo es la transferencia multilingüe. Es un caso concreto Zero-shot Learning (ZSL), cuyo objetivo es conseguir un modelo útil a partir de pocos o ningún ejemplo etiquetado.

Aprendizaje profundo 40 / 6

Global Vectors for Word Representation (GloVe)



¿Qué es GloVe?

Es una técnica para la obtención de vectores de palabras

- Al igual que word2vec, usa ventanas para obtener estadísticas locales
- Incorpora además estadísticas globales: coocurrencia entre palabras
 - Esto es, uso de dos o más palabras como unidad de significado (e.g. ¡no me digas!)

Idea: Se pueden deducir relaciones semánticas entre palabras mediante su matriz de coocurrencia

- Los cálculos para el cálculo de la matriz son demasiado extensos
- Un buen recurso es Intuitive Guide to Understanding GloVe Embeddings²⁰

20 Que, aunque se titule intuitive, cubre prácticamente todos los cálculos.



Después de GloVe

Cada vez es más fácil aprender una buena proyección de forma no supervisada

• Fantástico para las lenguas de bajos recursos y la traducción no supervisada²¹

Hay muchas más técnicas de embedding que se usan en la actualidad

- Embedding from Language Model (ELMo)²² está diseñado para oraciones y párrafos, aunque también se usa para palabras o caracteres
- Bidirectional Encoder Representations from Transformers (BERT) es una arquitectura avanzada que hace uso de transformers para comprender mejor el lenguaje
- Sentence-BERT²³ es una modificación sobre BERT para mejorar el rendimiento al trabajar sobre frases

21 Artículo: A survey of cross-lingual word embedding models.

22 Artículo: Deep contextualized word representations.

²³ Artículo: Sentence-bert: Sentence embeddings using siamese bert-networks.

Aprendizaje profundo

Arquitecturas y problemas

Universidad Politicanica de Madrid INFORMÁTICOS

Redes neuronales aplicadas al NLP

Desde el año 2013 las ANNs son usadas en NLP, centrándose en tres arquitecturas:

- RNN: La elección obvia para secuencias dinámicas, omnipresentes en NLP
 - Hasta 2013²⁴ se pensaba que las RNNs eran difíciles de entrenar; En la actualidad no es así
- CNN: Ampliamente utilizadas en visión, se aplican también al lenguaje²⁵
 - En texto los filtros solo se mueven a lo largo de la dimensión temporal
 - Más paralelizables: cada instante depende del contexto local, no de todos el histórico
 - CNNs y RNNs se suelen combinar²⁶ e incluso usar para acelerar LSTMs²⁷.
- Recursive Neural Networks: El lenguaje es intrínsecamente jerárquico
 - ∘ Secuencia ≡ árbol, donde cada nodo calcula una representación a partir de las de los hijos
- 24 Artículo: Training recurrent neural networks.
- 25 Artículos: A convolutional neural network for modelling sentences y Convolutional neural networks for sentence classification.
- ²⁶ Artículo: Dimensional sentiment analysis using a regional cnn-lstm model.
- 27 Artículo: Logical syntax and semantics: Their linguistic relevance.
- 28 Artículo: Recursive deep models for semantic compositionality over a sentiment treebank.
- ²⁹ Artículo: Improved semantic representations from tree-structured long short-term memory networks.

Aprendizaje profundo 45 / 6



Redes neuronales convolucionales

¿Por qué son útiles? Dos razones fundamentales:

- Útiles para clasificación donde pueden existir pistas locales en los datos de entrada
- Más rápidas y sencillas de codificar que las RNN

Figura 12 Convolución 1D aplicada al NLP.

Además, estamos enfocando el NLP desde una perpectiva de DL, y las CNNs son DL

Y funcionan como sustitución directa de las RNN, todo ventajas

En definitiva, nos ayudarán a conocer lo más básico del problema fácil y rápidamente

Aprendizaje profundo 46 / 64



Redes neuronales recurrentes simples

Son la primera aproximación recurrente obvia para el NLP

• No son muy usadas, pero sirven como para comprender arquitecturas más complejas

Afortunadamente, todas las interfaces de aprendizaje automático son iguales

- Bueno, quizá las RNNs sean un poco más complejas, pero mínimamente
- Casi se pueden utilizar como sustitutos de cualquier otro modelo basado en ANNs

Aprendizaje profundo 47 / 64



Redes neuronales recurrentes bidireccionales

Supongamos que queremos identificar personas y compañías (Fuente: Fallout 2)

- General clothing cannot be repaired by merchants that offer repair services
- General Atomics International has the finest industrial robots in the world
- General Constantine Chase is a gruff and determined general officer
- Ninguna RNN simple, por sí misma, tendrá contexto suficiente al analizar General

Las RNN bidireccionales surgen como solución a este problema de falta de contexto

- Después de todo, nosotros humanos al leer vemos toda la frase simultáneamente
- Son RNN pero en dos pasos: secuencia directa más secuencia en orden inverso

Apenas implica cambios en el código: de LSTM(M) a Bidirectional(LSTM(M))

Aprendizaje profundo 48 / 64



Sequence to sequence (seq2seq) (I)

Esta arquitectura se compone normalmente de dos componentes clave:

- Encoder: Procesa y codifica la secuencia de entrada en un único vector de contexto
- Decoder: Genera toda una secuencia a partir del vector de contexto

Figura 13: Esquema de arquitectura seq2seq para un problema de pregunta-respuesta.

Sí, lo de codificar y decodificar es una idea que se lleva mucho en DL

Aprendizaje profundo 49 / 64



Sequence to sequence (seq2seq) (II)

Sobre el encoder:

- No se usa la salida de la red porque no estamos haciendo ninguna predicción
 - \circ Sólo mantenemos el estado final h_t (y c_t si usamos una LSTM)
 - En keras: return_sequences=False
- Representa de alguna manera la secuencia de entrada en un vector
 - Se llama encoder porque codifica/comprime la entrada original

Sobre el decoder:

- Equivalente a un problema one-to-many
- Debe tener el mismo tamaño de vector para el estado
 - \circ El estado final anterior debe pasarse como estado inicial de esta nueva red h_0^\prime
- El vector de entrada X será un token <50S> (Start of Sequence)

Aprendizaje profundo 50 / 64



Seq2seq: Detalles de implementación

El uso del token <50S> más y(t) como x(t+1) funciona bien para generar predicciones

- Para el entrenamiento, sin embargo, funciona mucho mejor el teacher forcing
 - ∘ Ofrecer la verdadera secuencia destino como Xt en lugar de la palabra generada en Yt−1
- ¿Por qué? Porque es difícil aprender a generar toda la secuencia de una vez
- Los humanos procedemos de forma similar cuando estamos aprendiendo un idioma
 - Cuando vamos traduciendo en un idioma extranjero, cometemos errores
 - Si nadie nos corrige en un principio, lo más normal es que vayamos cayendo en barrena
 - Si un profesor nos corrige, podemos seguir trabajando a partir de la frase corregida

Cuidado, si la secuencia no empieza por , la red aprenderá a copiar la entrada

Aprendizaje profundo 51 / 64

¡Atención!



¿Qué es esto del mecanismo de atención?

Una de esas ideas felices que de repente se convierten en la más influyente

• Seq2seq sigue sin solucionar bien el problema de la memoria a largo plazo

Figura 14: Esquema del mecanismo de atención en seq2seq.

Se inspira en el mecanismo de atención del cerebro

- En el encoder ahora interesan todos los estados ocultos
- El decoder usará como vector de contexto su suma ponderada

Aprendizaje profundo 53 / 64



Transformers (I)

Son la base del estado de la cuestión actual en NLP³⁰

- No deja de ser un modelo secuencia a secuencia
- A diferencia de los anteriores no utiliza RNNs

En los últimos años, las arquitecturas basadas en transformers han avanzado mucho:

- BERT³¹: Uno de los principales avances sobre el que hoy se apoyan muchos modelos
- GPT-3³²: Uno de los modelos más avanzados actualmente, el cual requiere licencia
 - Cosa que choca un poco con los principios de OpenAl³³, aunque existen alternativas abiertas³⁴
- ³⁰ Artículos: Attention is all you need, Transformers: State-of-the-art natural language processing.
- 31 Presentado por Google. Artículo: Bert: Pre-training of deep bidirectional transformers for language understanding.
- 32 Presentado por OpenAI. Artículo: Language models are few-shot learners.
- 33 La misión de OpenAI (openai.com) es asegurar que la AI beneficia a la humanidad en su conjunto.
- 34 Más información en https://eleuther.ai/projects/gpt-neo y https://eleuther.ai/projects/gpt-neox

Aprendizaje profundo 54 / 64



Transformers (y II)

Se trata de un modelo complejo del que sólo explicaremos por encima algunos detalles

Figura 15: Esquema de la arquitectura transformer. Fuente: Attention is all you need.

- Izquierda: encoder, derecha: decoder
- Los bloques de autoatención determinan con qué palabras del contexto está relacionada la que se está procesando
- Al ser un problema de generación de secuencia, en la decodificación se trabaja iterativamente (esto es, $X_t = Y_{t-1}$)
- La salida softmax indica qué palabra es la más probable a continuación

Principales desafíos

Los principales desafíos en el NLP



El lenguaje natural es **orgánico**, es decir, **poco consistente** (cambia, evoluciona, ...)

- Todo lo contrario a los lenguajes informáticos, cuyo objetivo es ser consistentes
- No involucran solo al lenguaje hablado: feedback y lenguaje no verbal, empatía, ...

Lo normal es que no estén bien construidos y que la gramática sea inconsistente

• Y aún así, y expresándonos mal, curiosamente la mayoría del tiempo nos entendemos

Tratar cada uno de sus retos por separado es complejo, pero todo a la vez una locura

• Por eso los problemas se suelen acotar **mucho** para simplificar su resolución

Vamos a ver cuáles son los principales desafíos que plantea el NLP

Algunos están moderadamente superados; otros siguen siendo un problema abierto

57 / 64



Ambigüedad en los lenguajes naturales

En lenguaje natural una palabra puede tener diferentes significados

- No sólo usamos el conocimiento de la lengua para decidir el significado de un texto
- También tenemos en cuenta factores como contexto, deseos, objetivos y creencias

No estamos limitados a palabras, también tenemos:

- Modismos (frases hechas): Echar una mano, Meter la pata, Comerse la cabeza, Romper a llorar, Matar el gusanillo, Ir de punta en blanco, ...
- Hipérboles: Más inútil que un karaoke de música clásica, repetirse más que un yogur de ajo, ...
- Expresiones generacionales: LOL, shippeo, renta mazo, ...
- Semántica ambigüa: Raúl llamó a su mujer, y también lo hizo Verónica

Aprendizaje profundo 58 / 64



Sesgos y prejuicios inherentes al lenguaje (I)

Algunos ejemplos de sesgo para ponernos en contexto

- Hombre es a mujer como desarrollador es a ama casa²
- Negro es a delincuente como blanco a policía³
- El sentimiento de ira es mayor en frases con más sustantivos femeninos²
- El de **ofensivo** es mayor en aquellos **tweets** escritos por **afroamericanos**⁴

En estos ejemplos, el algoritmo está expresando esencialmente estereotipos

- Algunos casos (p.ej. rey-reina) llevan implícitas propiedades en si (p.ej. el género)
- Otros casos no, pero el lenguaje se las asigna, generalmente, en forma de prejuicios

² Artículo: Mitigating gender bias in natural language processing: Literature review

3 Artículo: Black is to criminal as caucasian is to police: Detecting and removing multiclass bias in word embeddings

4 Artículo: Racial bias in hate speech and abusive language detection datasets

Aprendizaje profundo 59 / 64

Sesgos y prejuicios inherentes al lenguaje (y II)



Es esencial tratar los problemas de sesgo antes de que lleguen al mundo real

- Ejemplo: Sistema COMPAS, evaluación de probabilidad de reincidencia en crímenes⁵
 - Este sistema se ha utilizado en algunas de las cortes de justicia de los EEUU
 - Resultó tener un evidente sesgo implícito contra los ciudadanos afroamericanos
 - Hasta el doble de falsos positivos frente a ciudadanos caucásicos
 - Este sesgo implícito no se detectó antes de que se implantara el sistema
 - Se predijo injusta e incorrectamente que muchos afroamericanos volverían a delinguir

Pero, ¿cómo pueden ser parciales los algoritmos si no tienen emociones?

- No dejan de ser pizarras en blanco que aprenden los patrones que encuentran
- El problema son los datos, que poseen implícitamente sesgos
 - Además la moral de una sociedad evoluciona con el tiempo

⁵ El artículo Are Algorithms Building the New Infrastructure of Racism? aborda el problema de los sesgos y habla no solo del sistema COMPAS, sino de otros sistemas y casos reales donde el sesgo de los datos es relevante

60 / 64

Alternativas para mitigar el sesgo



Abordar el sesgo en conjuntos de datos

- Una opción, eliminar los conjuntos de datos existentes que contienen sesgos
- Otra, revisar datasets existentes y nuevos para eliminarlos
- La forma más aceptada de eliminar el sesgo es diversificarlo
- Muy costoso ya que requiere analizar datasets que no son precisamente pequeños

Abordar el sesgo en el propio modelo

- Modificar las representaciones vectoriales de las palabras en los propios modelos⁷
- Vía mucho más eficiente con resultados prometedores (aunque no infalibles)

⁶ El MIT retiró su conjunto de datos de visión computacional Tiny Images al descubir que estaba lleno de sesgos sociales, incluyendo racismo y misoginia.

⁷ Por ejemplo, los algoritmos Hard Debias y Double-Hard Debias (artículo: Double-Hard Debias: Tailoring Word Embeddings for Gender Bias Mitigation) eliminan información estereotipada (p.ej. "secretaria" y "mujer") manteniendo al mismo tiempo la información de género útil (p.ej. "reina" y "mujer").

Aprendizaje profundo

Ironías del NLP



Ironía #1: En la era del Big Data sufrimos de escasez de datos para modelos de NLP

- Cada modelo requiere **terabytes de datos para** entender **un idioma** específico
- Los idiomas de los que existen tantos datos se denominan high resource languages
 - Sólo 20 de los cerca de 7000 idiomas existentes se pueden considerar de este tipo

Ironía #2: Nos hemos centrado en los idiomas que se enseñan bien en todo el mundo

- La mayoría de la gente del planeta habla un idioma considerado de escasos recursos
- Puede parecer que desde un punto de vista utilitarista, no merece la pena esforzarse
 - Después de todo, sólo disponemos de pequeñas cantidades de datos de estos idiomas
 - Los beneficios obtenidos serán limitados en comparación con el esfuerzo
- Un objetivo clave del NLP es construir sistemas para romper barreras
 - Modelos que permitan a la gente leer noticias escritas en otros idiomas
 - Sistemas para hacer preguntas sobre su salud cuando no tienen acceso a un médico

Aprendizaje profundo 62 / 64

Universidad Politécnica Politécnica INFORMÁTICOS

La evaluación de los resultados

La técnica evoluciona, y con ella se allana el camino a tareas más complejas

• Pero aún no disponemos de herramientas para entender por qué ciertas técnicas y arquitecturas funcionan mejor que otras en según qué escenarios

Es un problema bastante descuidado pero que es extremadamente importante

- Es necesario entender por qué hay enfoques que funcionan y otros no
- Sabiendo esto, debemos desarrollar medidas de evaluación basadas en ello

Necesitamos una nueva generación de conjuntos de datos y técnicas de evaluación

- Así podremos validar si nuestras técnicas generalizan la variedad de un idioma
- También podríamos conseguir conjuntos de datos de inferencia en lenguaje natural mucho más eficientes

Aprendizaje profundo 63 / 64

Gracias